第一章
机器学习和Scikit-learn介绍

目录

- 机器学习概述
  - 定义和历史介绍
  - 分类指标
  - 机器学习的基本方法
  - 过度拟合问题
  - 模型选择
- 机器学习常用工具
- Scikit-learn概览
- 案例：使用线性回归构建房价预测模型

目录

- 机器学习概述
  - 定义和历史介绍
  - 分类指标
  - 机器学习的基本方法
  - 过度拟合问题
  - 模型选择
- 机器学习常用工具
- Scikit-learn概览
- 案例：使用线性回归构建房价预测模型

机器学习

- 机器学习有下面几种定义：
  - 机器学习是一门人工智能的科学，该领域的主要研究对象是人工智能，特别是如何在经验学习中改善具体算法的性能。
  - 机器学习是对能通过经验自动改进的计算机算法的研究。
  - 机器学习是用数据或以往的经验，以此优化计算机程序的性能标准。

> We define *machine learning* as a set of methods that can automatically detect patterns in data, and then use the uncovered patterns to predict future data, or to perform other kinds of decision making under uncertainty (such as planning how to collect more data!).
>
> — 《Machine Learning: A probabilistic perspective》

人工智能、机器学习、深度学习

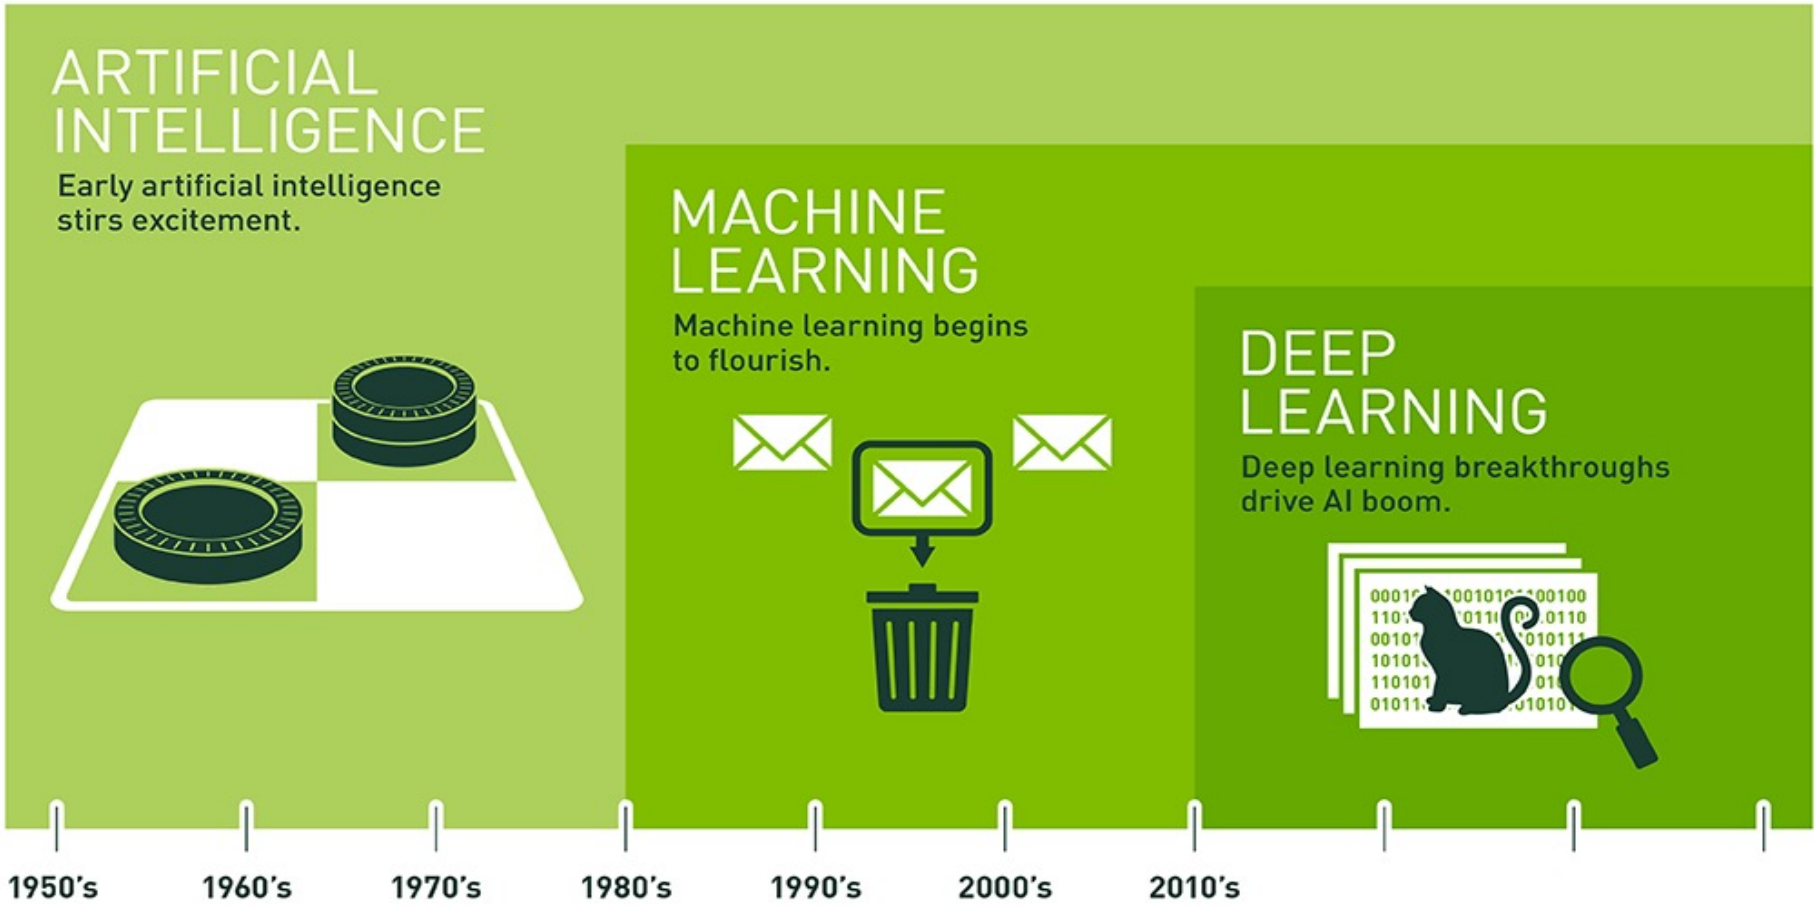

Since an early flush of optimism in the 1950s, smaller subsets of artificial intelligence – first machine learning, then deep learning, a subset of machine learning – have created ever larger disruptions.

By: Open Data Science on Twitter: "What's the Difference Between Artificial Intelligence, Machine Learning, and Deep Learning?

机器学习的问题：概述

数据

mpg	cylinders	displacement	horsepower	weight	acceleration	model year	origin	car name
18	8	307	130	3504	12	70	1	chevrolet chevelle malibu
15	8	350	165	3693	11.5	70	1	buick skylark 320
18	8	318	150	3436	11	70	1	plymouth satellite
16	8	304	150	3433	12	70	1	amc rebel sst
17	8	302	140	3449	10.5	70	1	ford torino
15	8	429	198	4341	10	70	1	ford galaxie 500
14	8	454	220	4354	9	70	1	chevrolet impala

啤酒尿不湿案例

聚类

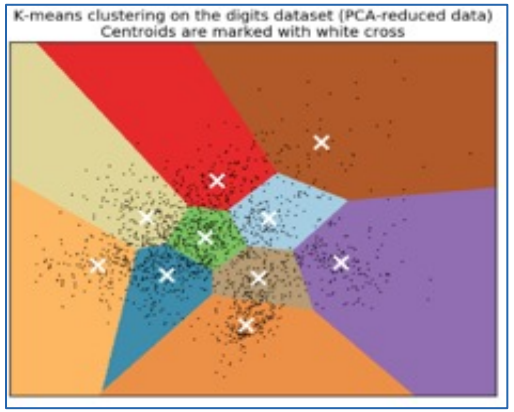

预测

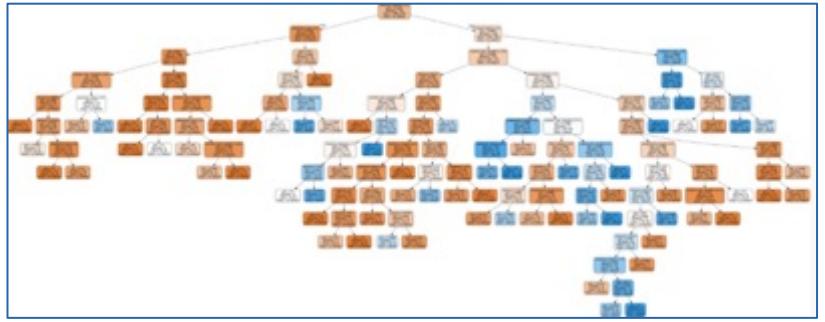

分类

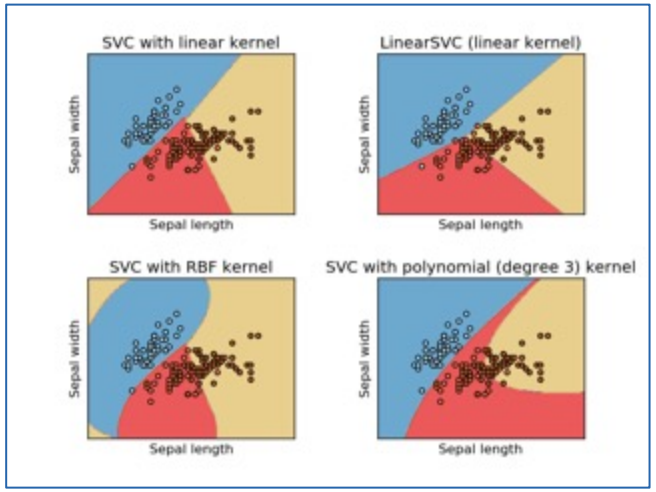

异常值检测

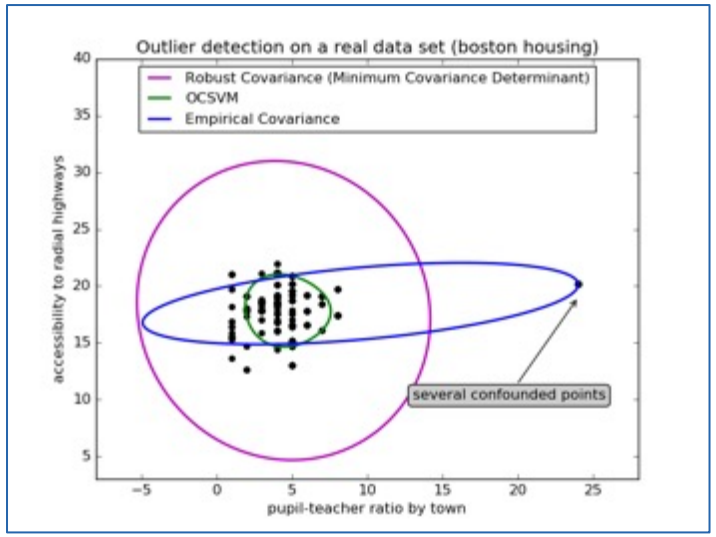

机器学习的基本方法

- 有监督学习（supervised learning）
  - 数据集中的样本带有标签，有明确目标
  - 回归和分类
- 无监督学习（unsupervised learning）
  - 数据集中的样本没有标签，没有明确目标
  - 聚类、降维、排序、密度估计、关联规则挖掘
- 强化学习（reinforcement learning）
  - 智慧决策的过程，通过过程模拟和观察来不断学习、提高决策能力
  - 例如：AlphaGo

基本概念

- 数据集：一组样本的集合。
- 样本：数据集的一行。一个样本包含一个或多个特征，此外还可能包含一个标签。
- 特征：在进行预测时使用的输入变量。

一个样本

建成年代 (特征)	面积 (特征)	布局 (特征)	房价 (标签)
1988	75	3室1厅	780
1988	60	2室1厅	705
1996	210	3室1厅	1400
2004	39	1室1厅	420
2010	90	2室2厅	998

基本概念

- 训练集：用于训练模型的数据集
- 测试集：用于测试模型的数据集
- 模型：建立数据的输入$\boldsymbol{x}$和输出y之间的映射关系
- 损失函数：
- 优化目标：$\min_{f \in F} \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(\boldsymbol{x}_i))$

$$y = f(\boldsymbol{x})$$

$$L(f(\boldsymbol{x}_i), y_i) = (f(\boldsymbol{x}_i) - y_i)^2$$

有监督学习

- 数据集中的样本带有标签
- 目标：找到样本到标签的最佳映射
- 典型方法
  - 回归模型：线性回归、岭回归、LASSO和回归样条等
  - 分类模型：逻辑回归、K近邻、决策树、支持向量机等

回归

- 典型的有监督任务，样本的标签为连续型，如收入、销量等
- 应用场景：
  - 流行病学：吸烟对死亡率和发病率影响的早期证据来自采用了回归分析的观察性证据
  - 金融：资本资产定价模型利用线性回归以及Beta系数的概念分析和计算投资的系统风险
  - 经济学：预测消费支出，固定投资支出，存货投资，一国出口产品购买，劳动力需求，劳动力供给

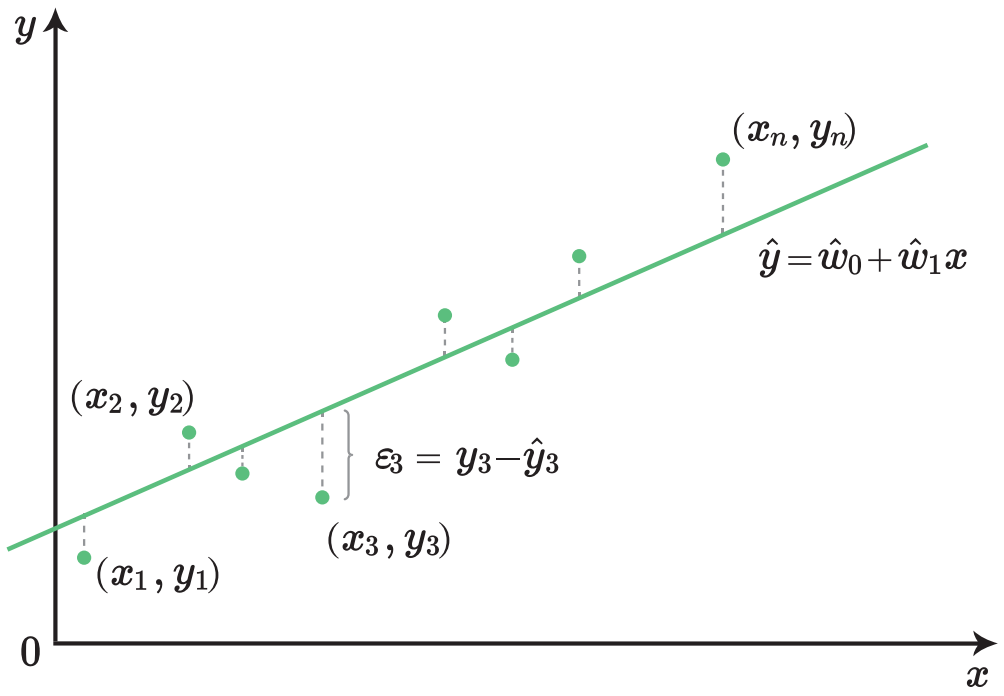

分类

- 典型的有监督学习任务，样本标签为离散型。包括二分类和多分类问题。
- 应用场景：
  - 信用风险评估
  - 预测肿瘤细胞是良性还是恶性
  - 邮件的分类：正常邮件/垃圾邮件
  - 电信客户流失分析

决策树——贷款违约预测

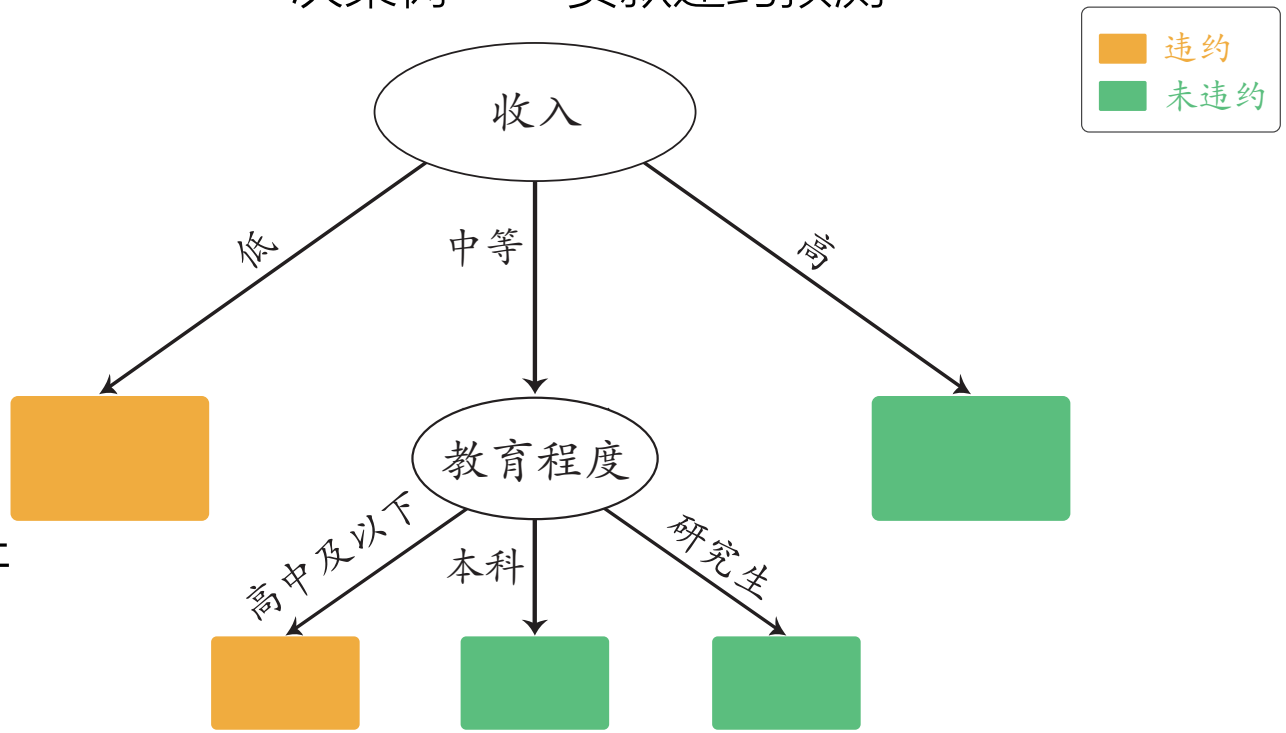

分类：支持向量机

线性可分数据

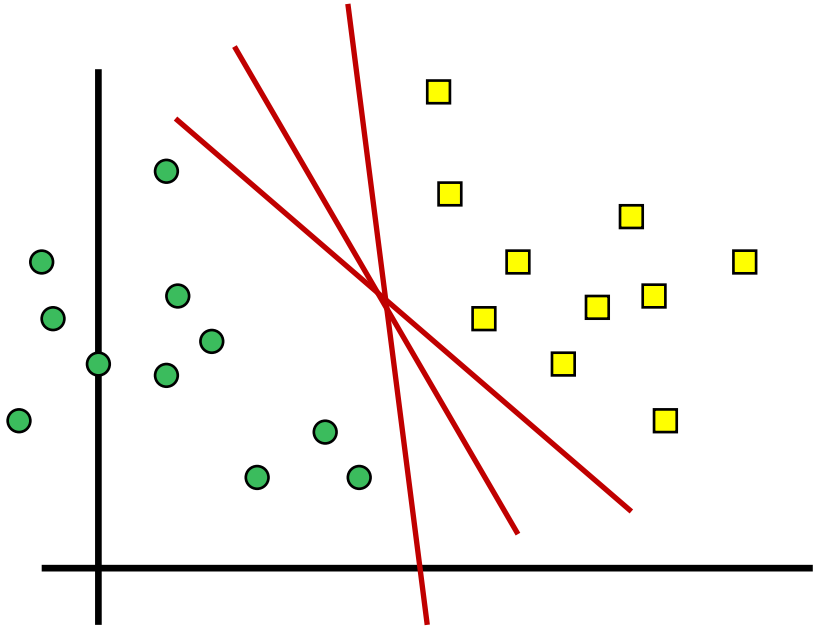

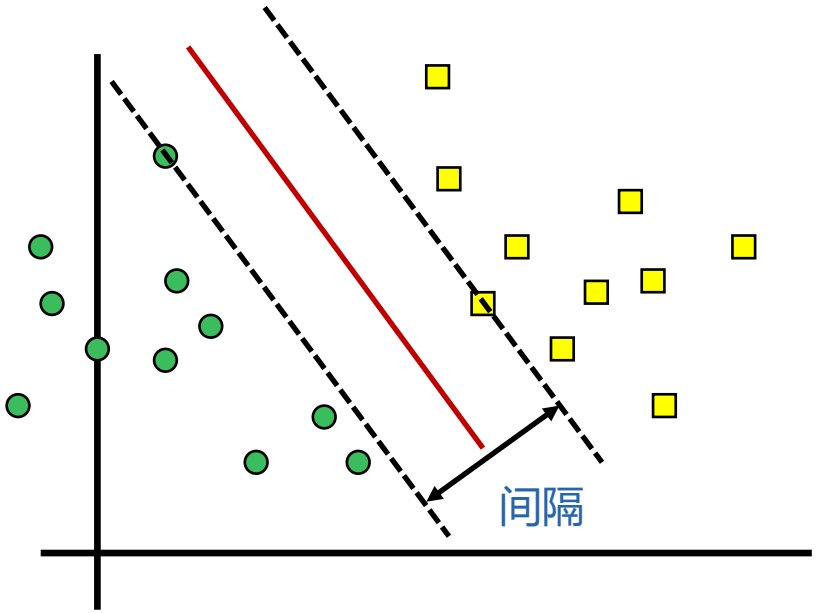

哪一条分割线更好？ ⇨ 具有最大间隔的分割线是最好的！

分类：支持向量机

如果数据并不是线性可分的?

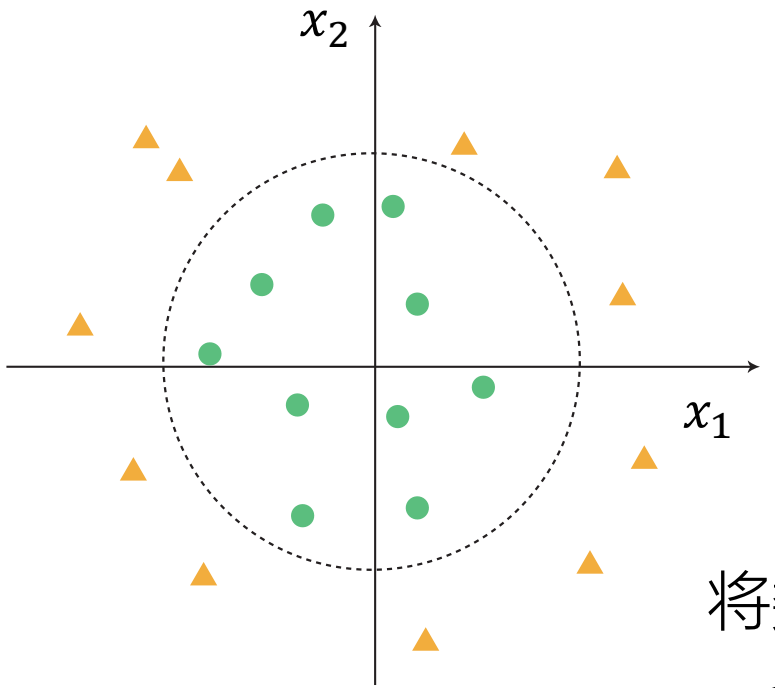

映射trick!

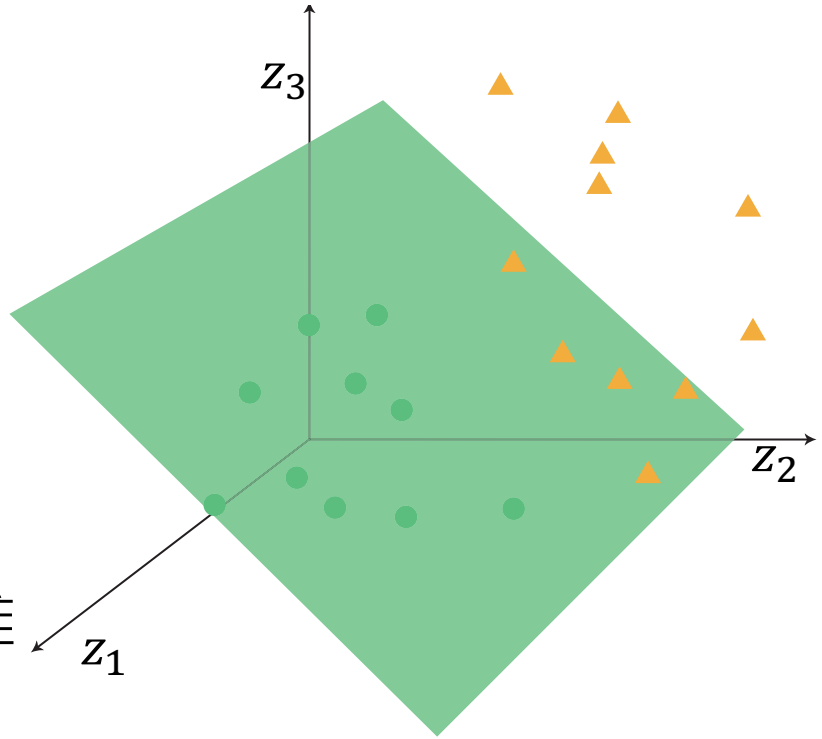

将数据点从2维空间映射到3维空间中，使得数据线性可分

无监督学习

- 可以处理没有标签的数据
- 根据数据本身的分布特点，挖掘反映数据的内在特性
- 典型方法
  - 聚类、降维、关联规则挖掘等

聚类

- 目的：将数据集中相似的样本进行分组，使得：
  - 同一组对象之间尽可能相似；
  - 不同组对象之间尽可能不相似。
- 应用场景：
  - 基因表达水平聚类：根据不同基因表达的时序特征进行聚类，得到基因表达处于信号通路上游还是下游的信息
  - 篮球运动员划分：根据球员相关数据，将其划分到不同类型（或者不同等级）的运动员阵营中
  - 客户分析：把客户细分成不同客户群，每个客户群有相似行为，做到精准营销

无监督学习：例子

K-Means聚类

1. 选择K个点作为初始质心
2. Repeat：
   - 将每个点指派到最近的质心，形成K个簇
   - 重新计算每个簇的质心
3. 直到质心不发生变化

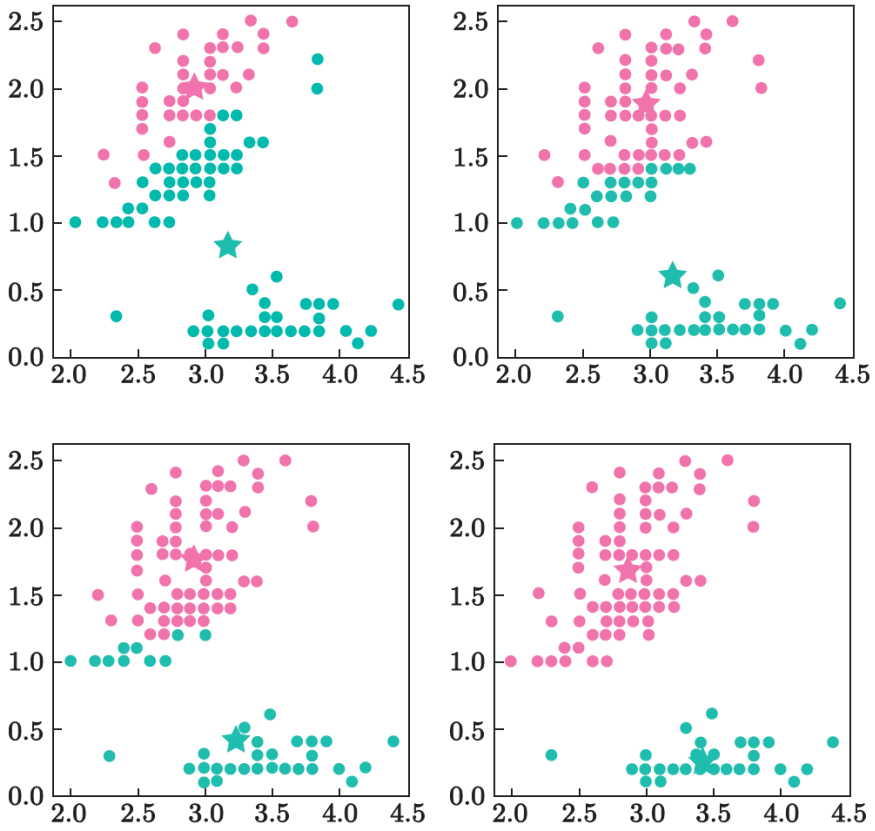

过度拟合问题

- 模型过于复杂(例如参数过多)，导致所选模型对已知数据预测得很好，但对未知数据预测很差。

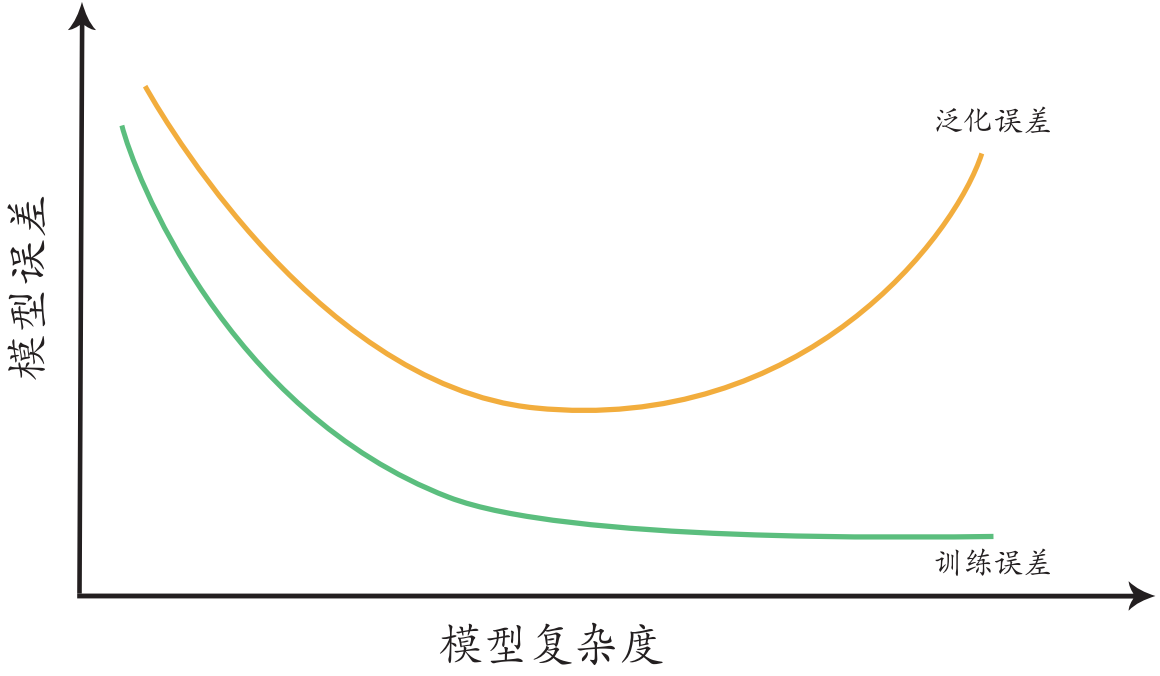

- 正则化：$\min_{f \in F} \frac{1}{n} \sum_{i=1}^{n} L(y_i, f(\boldsymbol{x}_i)) + \lambda J(f)$

- 正则化是模型选择的典型方法
- 在误差函数上加一个正则项，正则项通常为参数向量的范数
- 在训练误差和模型复杂度之间的权衡

模型选择

- **交叉验证**：基本想法是重复地使用数据。将数据集随机切分，将切分的数据集组合为训练集和测试集，在此基础上反复进行训练，测试和模型选择。
- **K折交叉验证**
  - 随机地将数据切分为k个互不相同大小相同的子集；
  - 每次利用$k-1$个子集的数据训练模型，余下的数据测试模型；
  - 最后选择在k次测评中平均性能最好的模型。

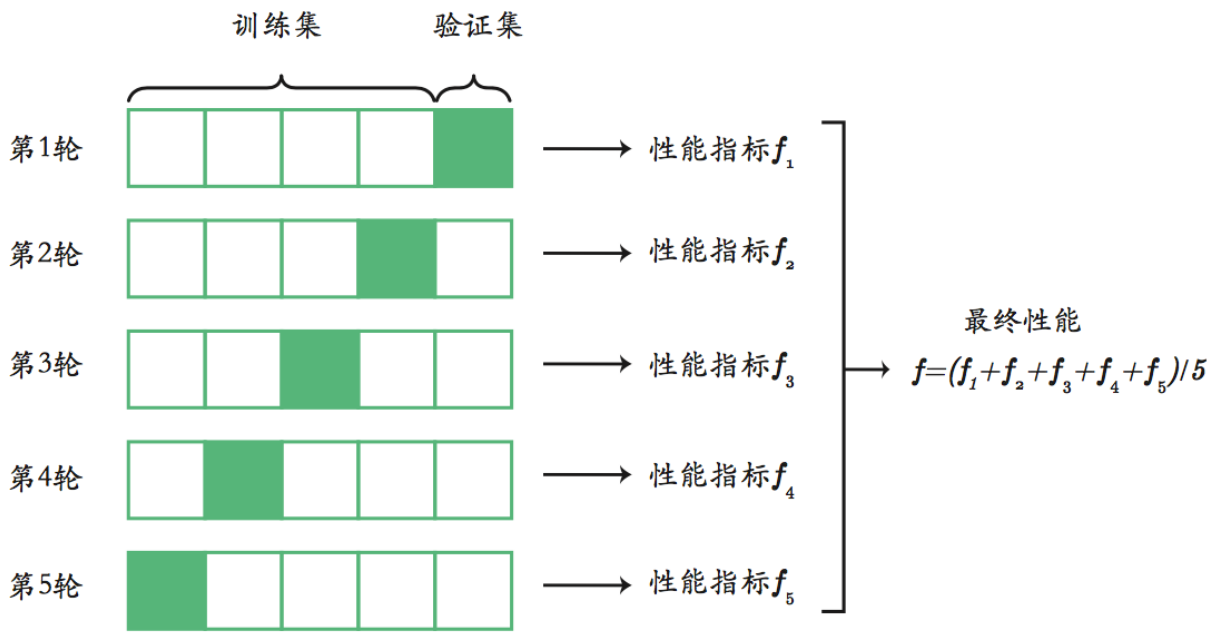

目录

- 机器学习概述
  - 定义和历史介绍
  - 分类指标
  - 机器学习的基本方法
  - 过度拟合问题
  - 模型选择
- 机器学习常用工具
- Scikit-learn概览
- 案例：使用线性回归构建房价预测模型

机器学习常用工具

Python 机器学习工具生态圈介绍

数据采集

数据存储与管

Scrapy

Beautiful Soup

"A tremendous boon." -- Python411 Podcast

27.10 MySQL Python API

PyMongo 3.7.1

PySpark is the Python API for Spark

Requests

SciPy

NumPy

pandas

$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$

StatsModels

Statistics in Python

scikits learn

machine learning in Python

PYTORCH

matplotlib

Seaborn

plotnine

NumPy

NumPy是Python用于科学计算的第三方库，它主要包括：

- 一个强大的n维数组对象
- 广播功能
- 有用的线性代数、傅立叶变换和随机数能力

NumPy还可以用作通用数据的有效多维容器。

可以定义任意的数据类型。

这允许NumPy无缝地和快速地与各种各样的数据库集成。

NumPy的安装

- 若电脑中已安装了Anaconda科学计算环境，由于Anaconda中已包含大量常用库，则可直接使用NumPy，无须再安装。

- 使用pip进行NumPy的安装：

```
pip install numpy
```

NumPy

NumPy数据结构为ndarray,一般有三种方式来创建:

- Python对象的转换
- 通过类似工厂函数NumPy内置函数生成：arange、linspace.....
- 从硬盘读取，loadtxt

```
np.arange(3,7)
```

```
array([3, 4, 5, 6])
```

```
import numpy as np
np.loadtxt("number.txt")
```

```
array([[0., 1.],
[2., 3.]])
```

```
np.linspace(1.0, 2.0, num=4)
```

```
array([1. , 1.33333333, 1.66666667, 2. ])
```

Pandas

Pandas可以在Python中执行从数据操作到数据分析和建模的整个数据分析工作流。

- 用于在内存数据结构和不同格式之间读取和写入数据的工具：CSV和文本文件、Microsoft Excel、SQL数据库和快速HDF5格式
- 可处理缺失数据

pandas

$$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$$

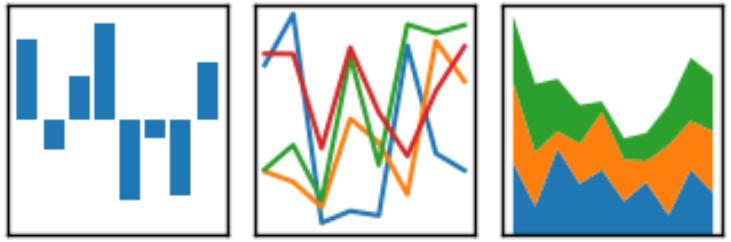

除了线性回归和面板回归之外，Pandas没有实现显著的建模功能；而Scikit-learn提供了显著的建模功能。

Pandas

- 主要数据结构有：
  - 一维的Series
  - 二维的DataFrame(类似于Excel或者SQL中的表)

- Pandas最初被作为金融数据分析工具而开发出来，因此，Pandas为时间序列分析提供了很好的支持。Pandas的名称来自于面板数据（panel data）和Python数据分析（data analysis）。

pandas

$$y_{it} = \beta' x_{it} + \mu_i + \epsilon_{it}$$

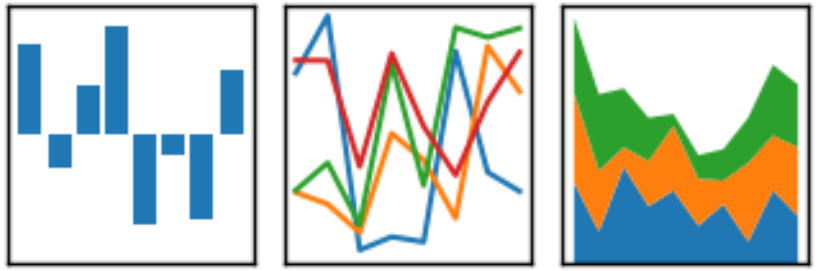

Pandas的安装

- 若电脑中已安装了Anaconda科学计算环境，由于Anaconda中已包含大量常用库，则可直接使用Pandas，无须再安装。

- 使用pip进行Pandas的安装：

```
pip install pandas
```

Scikit-learn概览

Scikit-learn

- Python用于数据建模的第三方库
- 实现主要的机器学习、数据挖掘算法

https://scikit-learn.org/

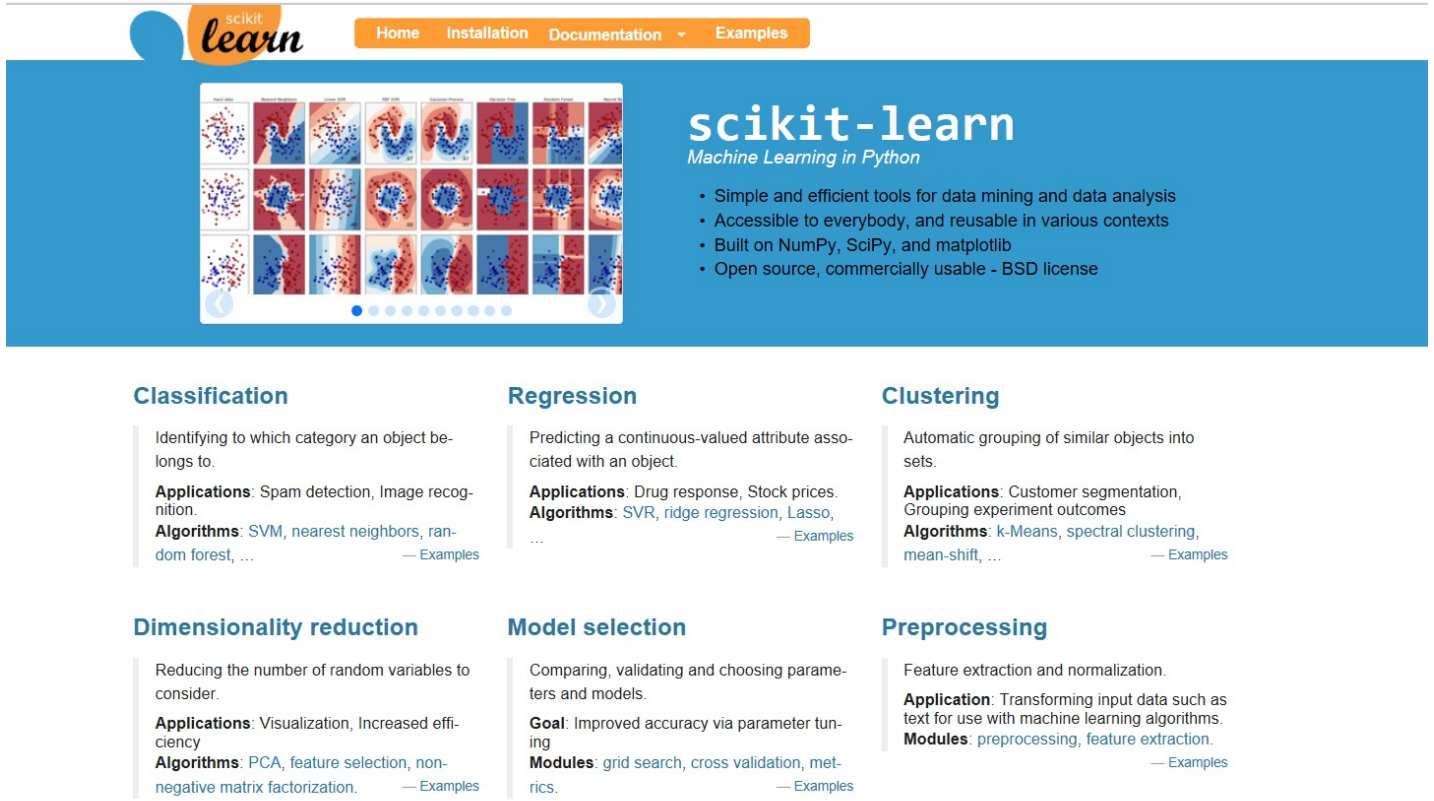

Scikit-learn的主要功能：

- 数据集预处理
- 数据集划分
- 构建模型
- 模型提升
- 模型评估

Scikit-learn的安装

- 若电脑中已安装了Anaconda科学计算环境，由于Anaconda中已包含大量常用库，则可直接使用Scikit-learn，无须再安装。

- 使用pip进行Scikit-learn的安装：

```
pip install -U scikit-learn
```

目录

- 机器学习概述
  - 定义和历史介绍
  - 分类指标
  - 机器学习的基本方法
  - 过度拟合问题
  - 模型选择
- 机器学习常用工具
- Scikit-learn概览
- 案例：使用线性回归构建房价预测模型

Scikit-learn基本建模流程

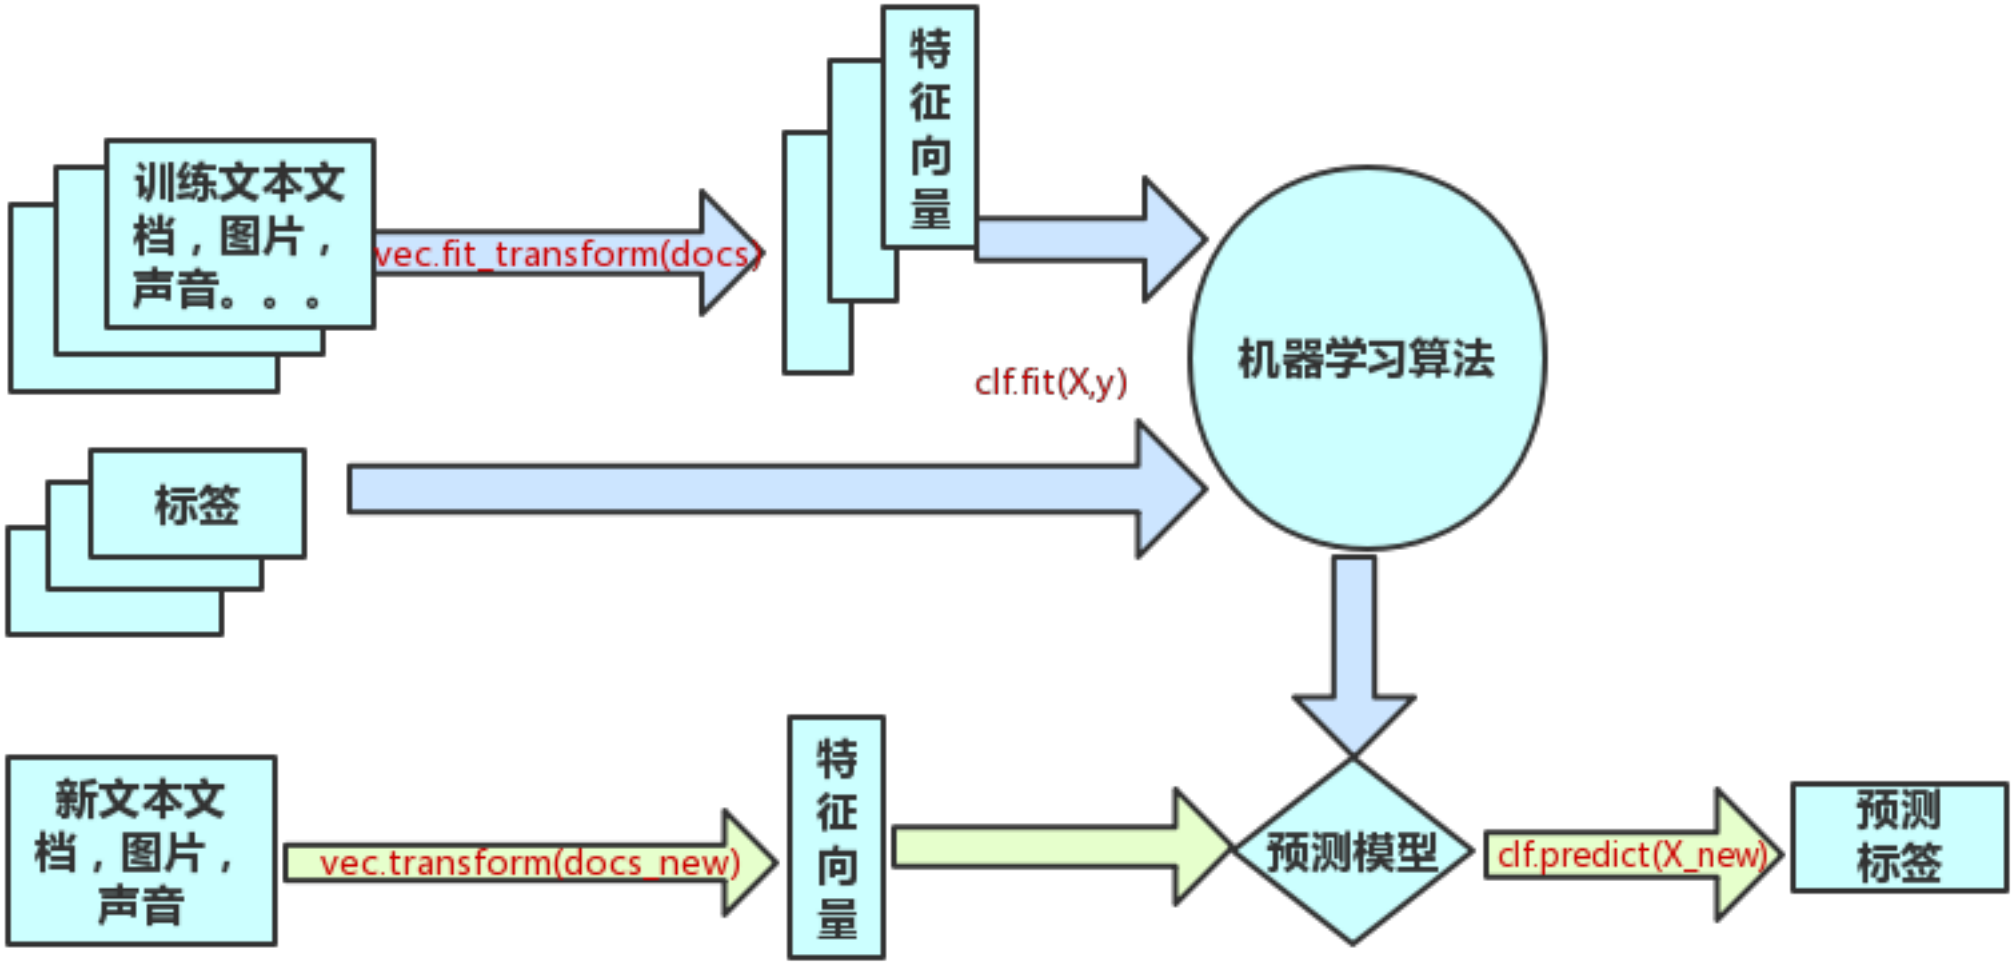

Scikit-learn常用函数

transform函数：数据转换

```
from sklearn import preprocessing
scaler =preprocessing.StandardScaler().fit(X_train)
X_train = scaler.transform(X_train)
X_test = scaler.transform(X_test)
```

fit函数：模型训练

```
from sklearn.linear_model import LinearRegression
lr = LinearRegression()
lr.fit(X_train, y_train)
```

predict函数：模型预测

```
y_pred = lr.predict(X_test)
```

Scikit-learn主要模块

模块	说明
preprocessing	数据预处理和标准化
feature_extraction	特征提取
feature_selection	特征选择
linear_model	线性模型
tree	基于树的模型
cluster	无监督聚类算法
discriminant_analysis	线性判别分析
ensemble	集成模型
metrics	模型评价
model_selection	模型选择与参数调优

Scikit-learn回归模块的主要算法

类	说明
linear_model.LinearRegression	普通最小二乘法
linear_model.Ridge	岭回归
linear_model.Lasso	用L1作为正则项的线性模型
linear_model.ElasticNet	将L1和L2组合作为正则项的线性回归
linear_model.BayesianRidge	贝叶斯岭回归
linear_model.TheilSenRegressor	泰尔森回归：稳健的多元回归模型
linear_model.HuberRegressor	对异常值具有鲁棒性的线性回归模型
linear_model.RANSACRegressor	随机采样一致性算法

Scikit-learn分类模块的主要算法

类	说明
linear_model.LogisticRegression	逻辑回归
neighbors.KNeighborsClassifier	K近邻
tree.DecisionTreeClassifier	决策树用于分类
naive_bayes.BernoulliNB	Bernoulli 贝叶斯
naive_bayes.GaussianNB	Gaussian贝叶斯
naive_bayes.MultinomialNB	多项式贝叶斯
svm.LinearSVC	线性支持向量分类

Scikit-learn聚类模块的主要算法

类	说明
cluster.KMeans	K-Means聚类
cluster.AgglomerativeClustering	层次聚类
cluster.DBSCAN	基于密度的噪声应用空间聚类（DBSCAN）
cluster.MeanShift	平均移位聚类
cluster.SpectralClustering	谱聚类

Scikit-learn降维模块的主要算法

类	说明
decomposition.PCA	主成分分析 (PCA)
decomposition.LatentDirichletAllocation	LDA
discriminant_analysis.LinearDiscriminantAnalysis	线性判别式分析(Linear Discriminant Analysis, LDA)
decomposition.FastICA，decomposition.fastica	独立成分分析
decomposition.NMF	非负矩阵分解 (NMF)
manifold.LocallyLinearEmbedding	局部线性映射
manifold.MDS	多维缩放

目录

- 机器学习概述
  - 定义和历史介绍
  - 分类指标
  - 机器学习的基本方法
  - 过度拟合问题
  - 模型选择
- 机器学习常用工具
- Scikit-learn概览
- 案例：使用线性回归构建房价预测模型

案例

某公司是撮合借款人和投资人的线上金融平台，它利用互联网模式建立了一种比传统银行更有效率的、能够在借款人和投资人之间自由配置资本的机制。通过线上平台，借款人和小微企业可以获得更低的利率，投资人则可以获得较好的收益。

本案例要求根据相关属性（详见数据说明部分），建立逻辑回归分类模型，对该平台用户的贷款状态进行预测，从而最大化规避风险。

数据集介绍

1.样本数：10000

2.特征数量： 12个相关属性（即12个指标变量）

1个类别变量（即loan_status，贷款状态）。

其中包括8个Default，8764个Fully Paid，1203个Charged Off，1个Late (16-30 days)，24个Late (31-120 days)。

测试模型时，将从各类别中分别抽取70%的数据作为训练集，用剩余样本进行分类结果测试。

特征	说明
CRIM	城镇人均犯罪率
ZN	大于25,000平方英尺的地块划分为住宅用地的比例
INDUS	每个城镇非零售业务的比例
CHAS	查尔斯河虚拟变量（如果管道界限= 1则为河; =0则不为河）
NOX	一氧化氮浓度（每千万份）
RM	每间住宅的平均房间数
AGE	自住房屋是在1940年之前建造的比例
DIS	到加州五个就业中心的加权距离
RAD	对径向高速公路的可达性指数
TAX	每10,000美元的全价物业税
PTRATIO	城镇的学生与教师比例
B	1000（Bk-0.63）^ 2其中Bk是城镇的黑人的比例
LSTAT	低社会阶层人口比例%
MEDV	以1000美元为单位的自住房屋的中位数价值

案例：使用线性回归构建房价预测模型

流程如下：

1. 导入工具包
2. 加载数据
3. 训练集-测试集划分
4. 模型构建
5. 模型预测与评价

1.导入工具包

```
import pandas as pd#导入pandas
#从sklearn的模型选择模块导入训练集-测试集划分类
from sklearn.model_selection import train_test_split
#从sklearn的线性模型模块导入线性回归类
from sklearn.linear_model import LinearRegression
#从sklearn的模型评价模块导入决定系数
from sklearn.metrics import r2_score
#从sklearn的模型评价模块导入均方误差
from sklearn.metrics import mean_squared_error
```

2. 加载数据

使用Pandas的read_csv函数从csv中读取数据，预测目标特征是‘target’，其余的数据为训练数据

```
data = pd.read_csv('BostonHousingData.csv')#读取csv

y = data['target']#数据标签

X = data.copy().drop(['target'], axis=1) #去掉标签列的完整数据
```

3. 训练集-测试集划分

训练集-测试集划分，一部分用于模型训练，一部分用于模型评估，比例为70%(训练)--30%(测试)

```
#X_train为训练数据， y_train为训练集标签，X_test为测试数据，y_test为测试集标签


X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3)
```

4.模型构建

LinearRegression(*fit_intercept=True,*
normalize=False,
copy_X=True,
n_jobs=None)

```
lr = LinearRegression()#创建一个线性回归对象

lr.fit(X_train, y_train)#拟合
```

5.模型预测与评价

```
y_pred = lr.predict(X_test)#模型预测

print(r2_score(y_test, y_pred))#模型评价, 决定系数

print(mean_squared_error(y_test, y_pred))#均方误差
```

0.7561429458476269
20.50487238687095

案例：完整代码

```
# 1)导入工具包
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score
# 2)加载数据
data = pd.read_csv('BostonHousingData.csv')
y = data[‘target’]
X = data.copy().drop(['target'], axis=1)
# 3)训练集-测试集划分
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.3)
# 4)模型构建与拟合
lr = LinearRegression()
lr.fit(X_train, y_train)#拟合
# 5)模型预测与评价
y_pred = lr.predict(X_test)
print(r2_score(y_test, y_pred))
```

总结

- 机器学习概述
  - 定义和历史介绍
  - 分类指标
  - 机器学习的基本方法
  - 过度拟合问题
  - 模型选择
- 机器学习常用工具
- Scikit-learn概览
- 案例：使用线性回归构建房价预测模型